

文章编号:1007-5321(2009)01-0005-05

神经网络和证据理论融合的管道泄漏诊断方法

陈 斌¹, 万江文², 吴银锋², 秦 楠¹

(1. 北京邮电大学 计算机科学与技术学院, 北京 100876; 2. 北京航空航天大学 仪器科学与光电工程学院, 北京 100083)

摘要: 针对传统管道泄漏诊断方法存在的准确率不高的问题, 结合无线传感器网络与信息融合技术, 提出一种神经网络和证据理论有机结合的管道泄漏诊断方法. 在普通节点处建立 2 个子神经网络模型来简化网络结构, 分别以负压波和声发射信号中的泄漏特征参数作为输入向量进行初始泄漏诊断; 然后将神经网络的识别结果作为证据的基本概率分配, 从而实现了赋值的客观化; 采用改进的证据组合规则, 在普通节点和汇聚节点处进行两级证据合成, 充分利用了网络中各种冗余和互补的泄漏信息. 实验结果表明, 该方法显著提高了管道泄漏诊断的准确率, 降低了识别的不确定性.

关键词: 泄漏诊断; 神经网络; 证据理论

中图分类号: TP391

文献标识码: A

A Pipeline Leakage Diagnosis for Fusing Neural Network and Evidence Theory

CHEN Bin¹, WAN Jiang-wen², WU Yin-feng², QIN Nan¹

(1. School of Computer Science and Technology, Beijing University of Posts and Telecommunications, Beijing 100876, China;

2. School of Instrument Science and Opto-Electronics Engineering, Beihang University, Beijing 100083, China)

Abstract: For reasons of low accuracy of traditional leakage, a pipeline leakage diagnosis method based on neural networks and evidence theory is presented by introducing wireless sensor networks and information fusion theory. Two sub-neural networks are established at normal node to simplify network structure. The leakage characteristic parameters of negative pressure wave and acoustic emission signals are used as input eigenvector respectively for primary diagnosis. Through making preliminary fusion results as the basic probability assignment of evidence, the impersonal valuations are realized. Finally, all evidences are aggregated at normal and sink node respectively by using the improved combination rules. The method makes full use of redundant and complementary leakage information. Numerical example shows that the proposed improves the leakage diagnosis accuracy and decreases the recognition uncertainty.

Key words: leakage diagnosis; neural networks; evidence theory

为提高管道泄漏诊断的精度, 同时解决现有人工巡检方式存在的实时性差、效率低的问题, 有学者开始研究基于无线传感器网络 (WSN, wireless sen-

sor networks) 的管道实时安全监控新技术^[1]. 利用网络节点上的压力、流量等多类传感器提取的泄漏征兆信息, 对这些具有冗余性、互补性和冲突性特征

收稿日期: 2008-06-16

基金项目: 国家“863 计划”项目 (2006AA01Z222); 北京市教育委员会共建项目

作者简介: 陈 斌 (1980—), 男, 博士生, E-mail: bchen@bupt.cn; 万江文 (1963—), 男, 教授, 博士生导师.

信息进行有效的融合处理,可提高监控系统的泄漏诊断准确率。

人工神经网络具有很强的自学习、自适应和自容错能力,在故障诊断等领域已经有了成功应用^[2-4],可用来解决泄漏诊断过程中数学建模难、信息不足和实时性差的问题。由于受训练样本选取、节点安装位置、背景干扰噪声以及传感器时变效应等因素的影响,神经网络的诊断结果存在一定的模糊性,同时,不同节点间的报告结果可能相互冲突,给汇聚节点的决策带来较大的困难。D-S 证据理论作为一种不确定性决策推理方法,可很好地解决诊断结果间的冲突问题,在模式识别、智能交通和故障检测等领域得到了广泛应用^[5-7]。基本概率赋值是利用证据理论进行决策分析的前提条件,其选取的好坏直接关系到融合结果的准确性和有效性,但目前大多依靠专家进行主观化赋值,影响了证据组合结果的准确性。若将神经网络的初始识别结果作为独立的证据,则可实现基本概率分配的客观化赋值,使不确定信息的融合具有很强的鲁棒性,便于最终的决策处理。为此,将神经网络与证据理论进行有机结合,使两者优势互补,提出了一种基于神经网络与证据理论的泄漏诊断方法。

1 诊断模型

1.1 基于 WSN 的监控网络结构

图 1 所示为基于无线传感器网络的管网安全监控系统结构,它由很多普通传感器节点、汇聚节点和 1 个控制管理中心构成。




图 1 监控系统的网络结构

采用分簇的结构设计方式。普通节点安装在天然气管道上,负责状态信号的采集、数据初步预处理以及将结果多跳发送至汇聚节点,且节点间采用管内或管外无线通信的方式。计算和存储能力均相对较强的汇聚节点作为簇头负责管理和维护一定范围内的普通传感器节点,并进行多源数据融合处理,判断管道是否发生泄漏、腐蚀以及建筑施工破坏等问

题,并以无线或有线通信方式将结果发送至控制管理中心,实现防范和预警功能。

1.2 神经网络和证据理论结合的诊断模型

为提高网络系统的泄漏诊断精度,首先利用小波变换等技术对泄漏检测信号(负压波和声发射)进行分析,提取出较为全面的泄漏特征参量,然后送入并行处理能力较强的神经网络进行初级识别。将管网安全监控过程中的泄漏征兆组成的集合称为征兆空间,管道安全状态组成的集合称为识别空间,利用神经网络进行故障诊断的过程就是实现从泄漏征兆空间到识别空间的非线性映射。

在众多的神经网络模型中,BP 网络的应用最为广泛和成熟。但当输入的特征数据较多时,网络结构变得较为复杂,需要大量的训练样本,并且网络的训练速度较慢;而简单的网络模型仅能处理问题的某一方面,且样本容易获得,结构容易确定。为此,采用 2 个简单的子神经网络结构,分别处理负压波和声发射信号所对应的低维子征兆空间,得出当前泄漏征兆信息对识别框架中各种命题的支持程度。

为了充分利用不同征兆空间的信息,将单节点处的 2 个 BP 子神经网络的诊断信息作为独立证据,利用证据理论进行信度的合成,以解决单神经网络存在的诊断模糊性问题。根据图 1 所示的网络结构可知,泄漏发生时,泄漏点周围可能有多个节点同时被检测到,且不同位置的节点诊断结果可能并不一致。为避免汇聚节点无法识别或难以决策,可进一步将单节点的融合结果作为独立证据,在汇聚节点处再一次进行证据合成,提高证据集对正确命题的聚焦度。

基于上述考虑,可构造出图 2 所示的三级融合泄漏诊断模型。首先利用神经网络对不同征兆信息进行处理,得出初始识别结果;然后依据各子神经网络的输出结果构造证据理论中的基本概率分配函数(BPAF, basic probability assignment function),利用证据组合规则分别在单节点和汇聚节点处进行两级证据融合;最后,依据决策规则得出诊断结果。

2 融合诊断算法设计

2.1 基于 BP 神经网络的初步诊断

建立 1 个神经网络模型须涉及输入向量的选择、隐含层数及其神经元个数的确定和诊断原则等。网络中的普通节点均采用相同的神经网络结构。图 3 所示为子 BP 神经网络结构模型,其中 $X_i (i = 1,$

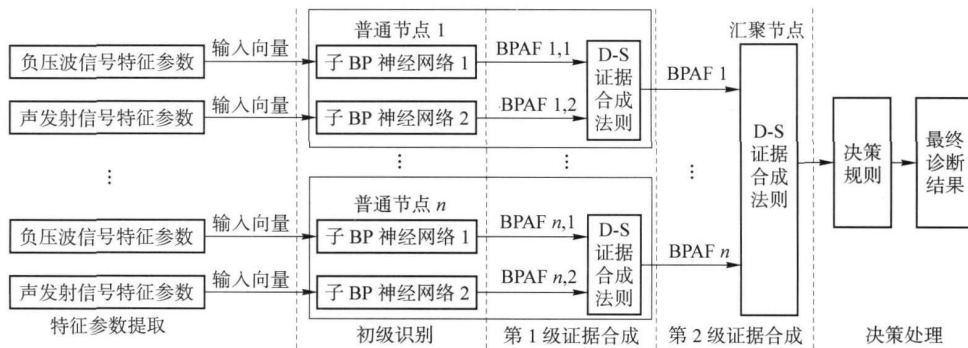


图 2 融合诊断模型

2, ..., p) 为输入的泄漏特征参数 (布尔值), $Y_j (j = 1, 2, \dots, q)$ 为神经网络处理后的输出结果。




图 3 BP 神经网络结构

1) 构造各参数子空间

根据泄漏诊断应用的需求分析,网络的输出节点数选为 3,其理想目标矢量 $T = [100; 010; 001]$, 分别表示正常、小泄漏和大泄漏 3 种不同的管道状态。提取负压波信号的均值、平均幅值、峰值、方差、裕度因子和峰值频率共 6 个参数作为输入特征向量,构建子 BP 神经网络 1 (简称 BPN1); 提取声发射信号的平均幅值、均方根、峰值频率、概率密度和 4 个频带能量分布系数 (不同尺度下小波分解的能量与总能量的比值) 共 8 个参数作为输入特征向量,构建子 BP 神经网络 2 (简称 BPN2)。

2) 隐层神经元数的确定

隐层节点数的确定是神经网络设计中非常重要的 1 个环节,它与求解问题的要求、输入输出神经元数都有直接的关系。本文采用“试优法”来确定隐含层节点的个数:根据经验公式确定隐含层中节点数目的范围,设计 1 个隐含层神经元数目可变的 BP 神经网络结构,基于相同的训练目标精度、训练样本和测试样本数,通过对比不同隐层节点数目的训练次数和识别精度,选取最佳的隐含层神经元数。

最优的隐含层节点数可由

$$n_1 = \sqrt{p + q} + \quad (1)$$

确定,其中, $= 1 \sim 10$; p 为输入神经元数; q 为输出

神经元数。

3) 网络参数优化

神经网络的学习过程中,采用标准的 BP 算法往往由于学习速率选择不当而导致算法收敛过程慢或者无法收敛。为此,采用启发式的改进 BP 算法对网络进行训练,动态改变学习速率,权值和阈值调整公式为

$$W^d(k) = W^d(k-1) - (1 - \alpha) \alpha s^d (a^{d-1})^T \quad (2)$$

$$b^d(k) = b^d(k-1) - (1 - \alpha) \alpha s^d \quad (3)$$

其中, α 为动量因子,一般取 0.95; α 为学习速度; $W^d(k)$ 、 $b^d(k)$ 分别为第 d 层的权值向量、阈值向量; s^d 为敏感性函数。加入动量项之后,可在保证算法稳定的前提下使用更高的学习速度,而不会产生振荡以致无法收敛。

2.2 基于证据理论的决策诊断

针对管道泄漏诊断的实际应用要求,构造如下的 D-S 证据理论决策诊断模型。

1) 识别框架

证据理论中,由一些完备的互不相容的元素组成的集合称为识别框架。管道泄漏的识别框架 $\Omega = \{A_1, A_2, A_3\}$,命题 A_1 表示“正常”; A_2 表示“小泄漏”; A_3 表示“大泄漏”。

2) 基本概率分配

设节点上第 $i (i = 1, 2)$ 个子 BP 神经网络的第 $j (j = 1, 2, 3)$ 个输出值为 $Y_i(j)$ 。通过输入大量测试数据至训练好的子 BP 神经网络模型,得到网络的诊断可靠性系数 λ_i ,这里分别取 0.88 和 0.92。

第 1 级证据合成时,分别将 BPN1 和 BPN2 的输出值进行归一化处理后作为辨识框架的 1 个证据体,第 i 条证据的基本概率分配赋值的计算公式为

$$m_i^1(A_j) = \frac{\lambda_i Y_i(j)}{\sum_{j=1} Y_i(j)} \quad (4)$$

$$m_i^1(Q) = 1 - \alpha_i \quad (5)$$

然后依据单节点的融合结果构造第 2 级证据合成时的基本概率分配函数。

3) 证据合成

设 m_1 和 m_2 分别为同一识别框架 Q 上的基本概率分配函数, 焦元分别为 $A_i (i = 1, 2, \dots, K)$ 和 $B_j (j = 1, 2, \dots, L)$, 则 2 条证据的合成公式为

$$m_{1 \odot 2}(A) = 0, \quad A = \emptyset$$

$$m_{1 \odot 2}(A) = \frac{m_1(A_i) m_2(B_j)}{1 - K} \quad (6)$$

其中, $K = \frac{m_1(A_i) m_2(B_j)}{A_i \cap B_j = \emptyset}$, 表示证据冲突的程度; \odot 表示直和运算。

利用式(6), 在单节点处进行第 1 级证据合成。假设簇内共有 N 个节点, 第 1 级证据合成后, 可得证据集 $\{m_l^2(A_j)\}, l = 1, 2, \dots, N$ 。

考虑到实际的管道泄漏诊断过程中, 检测节点距离泄漏点越近, 提取到的泄漏特征信号相对越强, 诊断结果的可靠性越高; 反之, 距离越远, 泄漏信号中的干扰成分越多, 诊断结果越不可靠。为减小不可靠证据对组合结果的影响, 提高证据集对正确命题的聚焦度, 在第 2 级证据融合时, 对证据集加以预处理后再利用式(6)进行组合计算。下面给出基于距离参数的预处理方法。

假设距离泄漏点最近(大小为 d)的传感器节点的可靠度为 1, 则可利用以下方法计算证据集中不同证据的可靠度。

$$\left. \begin{aligned} d = \min(d_l), \quad l = 1, 2, \dots, N \\ C_l(d/d_l), \quad 0 < C_l \leq 1 \end{aligned} \right\} \quad (7)$$

其中, C_l 为影响因子, 根据实际泄漏诊断时的节点放置距离, 经仿真调试后确定为 5。预处理后各证据的基本概率分配函数为

$$m_l^*(A_j) = C_l m_l^2(A_j), \quad A_j \in \emptyset$$

$$m_l^*(Q) = 1 - \sum_{A_j \in Q} m_l^*(A_j) \quad (8)$$

4) 最大信任度值决策法

根据组合得到的具有证据结构特征的融合结果, 可采用最大信任度值法做出决策判断。

设 $\exists A_1, A_2 \subset Q$, 且 $m(A_1) = \max\{m(A_k), A_k \subset Q\}$, $m(A_2) = \max\{m(A_k), A_k \subset Q, \text{ 且 } A_k \not\subset A_1\}$, 若满足

$$\left. \begin{aligned} m(A_1) - m(A_2) &> \alpha_1 \\ m(Q) &< \alpha_2 \\ m(A_1) &> m(Q) \end{aligned} \right\} \quad (9)$$

则诊断结果为 A_1 。其中 α_1, α_2 为预先设定的阈值。根据实际泄漏诊断情况, 经大量仿真实验后将 α_1 确定为 0.3, α_2 确定为 0.15。

3 实验分析

通过实验室里的管道泄漏模拟装置, 分别独立地选取 120 组(每种状态各 40 组)样本数据来训练 BPN1 和 BPN2。利用 Matlab7.0 的神经网络模块进行网络训练, 参数设置如下: 训练精度为 0.01, 学习速度为 0.95, 隐层和输出层分别采用 S 型对数函数和线性传输函数。待网络训练完毕后, 分别独立选取 120 组测试样本输入到 BPN1 和 BPN2, 并对输出结果作归一化处理, 然后依据决策规则(见式(9))测试网络的实际识别效果。

根据经验公式, 结合输入特征向量和输出神经元数可知, 2 个子网络的隐含层神经元数均在 $[4, 13]$ 内取值。利用 Matlab 仿真计算了不同隐含层节点数目下, 达到同等训练精度时, BPN1 和 BPN2 的训练次数和误识率如表 1 所示。

表 1 网络训练次数和误识率的比较

神经元/ 个	BPN1		BPN2	
	训练数/ $\times 10^4$ 次	误识率/%	训练数/ $\times 10^4$ 次	误识率/%
4	5.63	6	3.71	5
5	7.12	6	2.85	3
6	0.84	4	2.27	7
7	4.05	10	1.92	6
8	0.96	9	2.13	6
9	2.15	13	3.85	9
10	3.52	5	2.82	7
11	1.21	6	1.39	3
12	1.98	7	2.37	10
13	1.15	4	1.64	8

根据测试结果, 确定 BPN1 的结构参数为“6-6-3”, BPN2 的结构参数为“8-11-3”, 此时网络不仅具有较快的收敛速度, 还有较高的正确识别率。同时可见, 不同的子神经网络其识别精度也存在差异。

管道某处发生小泄漏时, 检测的传感器节点数为 5 个, 各节点至泄漏点的距离依次为 50、120、155、200、95 m, 神经网络的初级识别后所确定的基本概率分配赋值函数如表 2 所示。此时, 节点 2 和节点 5 的诊断结果不满足式(9), 无法进行识别。

这是因为：1) 传感器自身缺陷、检测机理和对噪声敏感程度等差异，神经网络的输入特征向量存在一定程度的偏差；2) 神经网络训练时，训练样本不可能穷尽所有可能情况，诊断网络自身存在识别误差。

表 2 神经网络的初始识别结果

BPAF	A_1	A_2	A_3	Q
$m_{1,1}$	0.179 4	0.447 5	0.253 2	0.12
$m_{1,2}$	0.212 6	0.619 7	0.087 6	0.08
$m_{2,1}$	0.039 3	0.402 7	0.438 1	0.12
$m_{2,2}$	0.108 8	0.326 1	0.485 1	0.08
$m_{3,1}$	0.165 8	0.667 7	0.046 5	0.12
$m_{3,2}$	0.035 8	0.520 7	0.363 5	0.08
$m_{4,1}$	0.076 6	0.642 4	0.161 1	0.12
$m_{4,2}$	0.066 8	0.753 1	0.100 1	0.08
$m_{5,1}$	0.007 1	0.403 9	0.469 0	0.12
$m_{5,2}$	0.065 6	0.791 4	0.063 0	0.08

基于神经网络输出结果进行 2 级证据合成后，结果如表 3 和表 4 所示。

表 3 第 1 级证据合成结果

BPAF	A_1	A_2	A_3	Q
m_1	0.147 7	0.733 8	0.100 3	0.018 2
m_2	0.038 0	0.376 4	0.567 9	0.017 8
m_3	0.041 9	0.826 5	0.114 5	0.017 1
m_4	0.027 7	0.899 6	0.059 0	0.013 8
m_5	0.016 5	0.827 6	0.138 2	0.017 8

表 4 第 2 级证据合成结果

BPAF	A_1	A_2	A_3	Q
m	0.001 3	0.991 9	0.006 6	0.000 1

表 3 表明，经过第 1 级证据合成后，节点 5 对命题 A_2 的支持度提高到 0.827 6，而对命题 A_3 的支持度降到 0.138 2，诊断结果趋于合理；但对节点 2 而言，由于 $m_2(A_2) < m_2(A_3)$ ，所以仍倾向于支持命题 A_3 ，与其他 4 条证据相矛盾，汇聚节点据此将难以做出决策。由表 4 可见，经过第 2 级证据合成后，证据集对命题 A_2 的支持度为 0.991 9，对不确定性命题的支持度降到 0.000 1，显然满足式(9)，其诊断结果为“支持命题 A_2 ”，即发生了小泄漏。

可见，通过多级数据融合，不仅可解决神经网络存在的误识别问题，同时可提高证据集对正确命题的聚焦度，避免单级证据合成后仍存在的难以决策

问题。

4 结束语

结合无线传感器网络与多源数据融合技术，提出了一种三级融合管道泄漏诊断方法。采用“试优法”选取隐含层神经元数，提高了神经网络的训练速度和正确识别率；以 BP 子神经网络的初始识别结果作为证据的基本概率分配，实现了赋值的客观化；两级证据融合策略较好地解决了单神经网络识别或单节点上不同证据合成后可能存在的误判或难以决策问题，提高了泄漏诊断的准确率。仿真验证表明，新算法能满足管道泄漏诊断的要求。

参考文献：

[1] Stoianov I, Nachman L, Madden S, et al. PIPENET: a wireless sensor network for pipeline monitoring [C] 2007 International Symposium on Information Processing in Sensor Networks. Massachusetts: ACM Press, 2007: 264-273.

[2] Feng D C, Dias P J M. Study on information fusion based on wavelet neural network and evidence theory in fault diagnosis [C] 2007 International Conference on Electronic Measurement and Instruments. Xi 'an: IEEE Press, 2007: 3522-3526.

[3] Luis E O, Beatriz M T. A method to estimate emission rates from industrial stacks based on neural networks[J]. Chemosphere, 2004, 57(7): 691-696.

[4] 葛艳, 王薇, 闫传军, 等. 基于模糊神经网络的 CDMA 网络故障诊断方法[J]. 北京邮电大学学报, 2007, 30(1): 123-126.

Ge Yan, Wang Wei, Yan Chuanjun, et al. A fuzzy neural network based fault diagnosis method for the CDMA network[J]. Journal of Beijing University of Posts and Telecommunications, 2007, 30(1): 123-126.

[5] Denoeux T, Masson M. EVCLUS: evidential clustering of proximity data[J]. IEEE Systems, Man and Cybernetics B, 2004, 34(1): 95-109.

[6] Laha A, Pal N R, Das J. Land cover classification using fuzzy rules and aggregation of contextual information through evidence theory[J]. IEEE Transaction on Geoscience and Remote Sensing, 2006, 44(6): 1633-1641.

[7] Zhao Wentao, Fang Tao, Jiang Yan. Data fusion using improved Dempster-Shafer evidence theory for vehicle detection[C] 2007 International Conference on Fuzzy Systems and Knowledge Discover. Haikou: IEEE Press, 2007: 487-491.